

Tema 8 · Estadística

Apunts

Contents

1 Població, mostra i variables	2
1.1 Tipus de variables	2
2 Organització de dades: taula de freqüències	3
2.1 Tipus de freqüències	3
2.2 Dades agrupades en intervals	3
3 Representació gràfica de dades	5
3.1 Diagrama de barres	5
3.2 Histograma	5
3.3 Polígon de freqüències	5
3.4 Diagrama de sectors (de pastís)	5
3.5 Diagrama de caixa i bigotis (<i>box plot</i>)	6
4 Mesures de posició central	7
4.1 La moda	7
4.2 La mediana	7
4.3 La mitjana aritmètica	8
5 Mesures de dispersió	9
5.1 El rang	9
5.2 La desviació de cada dada respecte a la mitjana	9
5.3 La variància	9
5.4 La desviació típica	10

1. Població, mostra i variables

L'**estadística** és la branca de les matemàtiques que s'ocupa de **recollir, organitzar, representar i interpretar** dades per extreure'n conclusions.

- **Població**: el conjunt complet d'elements que estudiem.
Exemple: tots els alumnes de l'institut.
- **Mostra**: un subconjunt representatiu de la població que podem mesurar.
Exemple: 30 alumnes seleccionats aleatòriament.
- **Individu**: cadascun dels elements de la població o mostra.
- **Variable estadística**: la característica que mesurem o observem.

1.1. Tipus de variables

Les variables estadístiques es classifiquen en:

- **Qualitatives**: prenen valors no numèrics (categories).
Exemples: color d'ulls, nom del mes, colour preferit.
- **Quantitatives**: prenen valors numèrics.
 - **Discretes**: valors aïllats (es compten).
Exemple: nombre de germans, puntuació d'un examen.
 - **Continues**: qualsevol valor dins d'un interval (es mesuren).
Exemple: alçada, temperatura, pes.

Exemple

Classifica les variables: edat (quantitativa discreta si en anys enters, contínua si en dies), color de cabells (qualitativa), nombre de telèfons mòbils (quantitativa discreta), velocitat d'un cotxe (quantitativa contínua).

Prova-ho tu

Classifica cada variable i di si és qualitativa, quantitativa discreta o contínua:

- Música preferida.
- Nombre de llibres llegits en un any.
- Temperatura màxima diària.
- Número de sabata.

2. Organització de dades: taula de freqüències

Un cop recollides les dades, el primer pas és organitzar-les en una **taula de freqüències**.

2.1. Tipus de freqüències

Donades N dades amb valors $x_1, x_2, \dots, x_k$:

- **Freqüència absoluta** (n_i): nombre de vegades que apareix el valor x_i .
- **Freqüència relativa** (f_i): proporció sobre el total. $f_i = \frac{n_i}{N}$. (Expressada en tant per 1 o com a percentatge.)
- **Freqüència absoluta acumulada** (N_i): suma de totes les freqüències absolutes fins a x_i inclòs:
 $N_i = n_1 + n_2 + \dots + n_i$.
- **Freqüència relativa acumulada** (F_i): $F_i = \frac{N_i}{N}$.

Verifications: $\sum_i n_i = N$ i $\sum_i f_i = 1$.

Exemple

Les notes (sobre 10) d'un grup de 20 alumnes en un examen de matemàtiques van ser:

6, 7, 8, 5, 9, 6, 7, 7, 8, 6, 5, 10, 7, 6, 8, 7, 9, 6, 7, 5

Construïm la taula de freqüències:

x_i (nota)	n_i	f_i	N_i	F_i
5	3	0,15	3	0,15
6	5	0,25	8	0,40
7	6	0,30	14	0,70
8	3	0,15	17	0,85
9	2	0,10	19	0,95
10	1	0,05	20	1,00
Total	20	1,00		

El 40% dels alumnes ($F_3 = 0,40$) van treure una nota de 6 o menys.

2.2. Dades agrupades en intervals

Quan les dades contínues o molt nombroses, s'agrupen en **intervals** (o classes): $[a_i, b_i)$.

- **Amplada** de l'interval: $c = b_i - a_i$ (habitualment constant).
- **Marca de classe** (m_i): punt mig de l'interval: $m_i = \frac{a_i + b_i}{2}$.
- S'utilitza la marca de classe per calcular la mitjana i la desviació típica.

Exemple

Les alçades (en cm) de 25 alumnes de 3r d'ESO:

Interval	m_i	n_i	f_i	N_i
[150, 155)	152,5	3	0,12	3
[155, 160)	157,5	7	0,28	10
[160, 165)	162,5	8	0,32	18
[165, 170)	167,5	5	0,20	23
[170, 175)	172,5	2	0,08	25
Total		25	1,00	

Prova-ho tu

Les temperatures màximes (en °C) de 15 dies d'estiu van ser:

28, 32, 31, 35, 33, 29, 30, 34, 32, 31, 28, 36, 33, 30, 29

Construeix la taula de freqüències completa (amb n_i , f_i , N_i , F_i).

3. Representació gràfica de dades

Les gràfiques permeten visualitzar les dades i detectar patrons d'un cop d'ull.

3.1. Diagrama de barres

El **diagrama de barres** representa les freqüències (absolutes o relatives) de cada valor mitjançant barres verticals (o horitzontals) de la mateixa amplada, separades entre elles.

- Adequat per a **variables qualitatives i quantitatives discretes**.
- L'alçada de cada barra = la freqüència del valor corresponent.

▲ UIII!

En un diagrama de barres les barres **no** s'han de tocar. Si es toquen, és un histograma (per a dades contínues o agrupades en intervals).

3.2. Histograma

L'**histograma** és similar al diagrama de barres però les barres **sí s'han de tocar** (els intervals són contigus). S'utilitza per a **variables contínues o dades agrupades en intervals**. L'eix horitzontal és una escala numèrica contínua.

3.3. Polígon de freqüències

El **polígon de freqüències** s'obté unint amb segments els punts (m_i, n_i) (marca de classe, freqüència absoluta) de cada interval. Es tanca l'extrem esquerre i dret en un punt de freqüència zero (un interval de més a cada banda).

Exemple

Per a les alçades del tema anterior, els punts del polígon de freqüències serien: $(147,5, 0)$ – $(152,5, 3)$ – $(157,5, 7)$ – $(162,5, 8)$ – $(167,5, 5)$ – $(172,5, 2)$ – $(177,5, 0)$.

3.4. Diagrama de sectors (de pastís)

En el **diagrama de sectors** cada valor o categoria ocupa un sector circular proporcional a la seva freqüència relativa. L'angle del sector és:

$$\alpha_i = f_i \cdot 360 = \frac{n_i}{N} \cdot 360.$$

Adequat per comparar parts d'un tot (percentatges). Evita fer-lo servir quan hi ha moltes categories (més de 6-7).

Exemple

En una enquesta sobre transport escolar: cotxe 40%, autobús 30%, a peu 20%, bicicleta 10%.
Angles: cotxe 144, autobús 108, a peu 72, bicicleta 36. Total: 360 ✓.

3.5. Diagrama de caixa i bigotis (*box plot*)

El **diagrama de caixa i bigotis** representa gràficament els cinc estadístics de posició clau d'un conjunt de dades:

Estadístic	Descripció
Q_1 (1r quartil)	valor que deixa el 25% de les dades per sota
Q_2 (mediana)	valor que deixa el 50% de les dades per sota
Q_3 (3r quartil)	valor que deixa el 75% de les dades per sota
Mínim	valor més petit (sense valors atípics)
Màxim	valor més gran (sense valors atípics)

La **caixa** va de Q_1 a Q_3 ; la línia central és la mediana. Els **bigotis** s'estenen fins al mínim i màxim no atípics.

Prova-ho tu

A partir d'una taula de freqüències de la secció anterior (o del teu exemple de les notes), dibuixa el diagrama de barres i el diagrama de sectors corresponents.

4. Mesures de posició central

Les **mesures de posició central** (o mesures de centralitat) resumeixen tota la informació d'un conjunt de dades en un sol valor representatiu.

4.1. La moda

La **moda** (M_o) és el valor que apareix amb més freqüència, és a dir, el que té la freqüència absoluta més gran.

- Pot haver-hi **cap moda** (totes les freqüències iguals), **una moda** (unimodal), **dues modes** (bimodal) o més.
- Aplicable a variables **qualitatives** i **quantitatives**.

Exemple

Dades: 3, 7, 5, 7, 2, 7, 4. La moda és $M_o = 7$ (apareix 3 vegades).

Dades: 1, 2, 2, 3, 3, 4. Bimodal: $M_o = 2$ i $M_o = 3$.

4.2. La mediana

La **mediana** (M_e) és el valor central quan les dades s'ordenen de menor a major. Deixa el 50% de les dades per sota i el 50% per sobre.

- 1 Ordena les dades de menor a major.
- 2 Si N és **imparell**: la mediana és el valor de la posició $\frac{N+1}{2}$.
- 3 Si N és **parell**: la mediana és la mitjana dels dos valors centrals (posicions $\frac{N}{2}$ i $\frac{N}{2} + 1$).

Exemple

$N = 7$ (imparell): 2, 3, 5, **7**, 8, 9, 10. Posició central: $\frac{8}{2} = 4$. $M_e = 7$.

$N = 6$ (parell): 2, 3, 5, **7, 8**, 9. Dos valors centrals: 5 i 7. $M_e = \frac{5+7}{2} = 6$.

Recordatori

La mediana és **robusta**: no li afecten els valors extrems (atípics). Si hi ha un valor molt gran o molt petit, la mediana no canvia gaire. La mitjana, en canvi, sí.

4.3. La mitjana aritmètica

La **mitjana aritmètica** ($\bar{x}$) és la suma de totes les dades dividida pel nombre total:

$$\bar{x} = \frac{x_1 + x_2 + \cdots + x_N}{N} = \frac{\sum_i x_i}{N}.$$

Amb una **taula de freqüències**:

$$\bar{x} = \frac{\sum_i n_i \cdot x_i}{N} = \sum_i f_i \cdot x_i.$$

Per a dades agrupades s'utilitza la marca de classe m_i en lloc de x_i .

Exemple

Les notes de l'exemple anterior (5×3 , 6×5 , 7×6 , 8×3 , 9×2 , 10×1 ; $N = 20$):

$$\bar{x} = \frac{5 \cdot 3 + 6 \cdot 5 + 7 \cdot 6 + 8 \cdot 3 + 9 \cdot 2 + 10 \cdot 1}{20} = \frac{15 + 30 + 42 + 24 + 18 + 10}{20} = \frac{139}{20} = 6,95.$$

⚠️ UIII!

La mitjana es veu **afectada pels valors extrems** (atípics). Si hi ha valors molt grans o molt petits, la mitjana pot ser poc representativa del grup. En aquest cas, la mediana pot ser millor.

Exemple: salaris d'un equip de 5 persones: 1000, 1200, 1100, 1050, 50 000 €. Mitjana: 10 870 € (poc representativa). Mediana: 1 100 € (molt més representativa).

Prova-ho tu

De les notes del grup: 4, 6, 7, 5, 8, 6, 9, 7, 6, 5, calcula la moda, la mediana i la mitjana. Quina mesura descriuràs al teu amic per resumir com va anar el grup?

5. Mesures de dispersió

Les mesures de posició central ens diuen on es concentren les dades, però no ens diuen si les dades estan molt agrupades o molt escampades. Per això necessitem les **mesures de dispersió**.

Exemple

Grup A: notes 7, 7, 7, 7, 7. Mitjana = 7. Dispersió = 0 (totes iguals).

Grup B: notes 3, 5, 7, 9, 11. Mitjana = 7. Dispersió gran (molt escampades).

Ambdós grups tenen la mateixa mitjana, però les dades del grup B estan molt més disperses.

5.1. El rang

El **rang** (o recorregut) és la diferència entre el valor màxim i el valor mínim:

$$R = x_{\max} - x_{\min}.$$

És una mesura senzilla però molt sensible als valors extrems.

Exemple

Grup A: $R = 7 - 7 = 0$. Grup B: $R = 11 - 3 = 8$.

5.2. La desviació de cada dada respecte a la mitjana

Per mesurar la dispersió de manera més precisa, mirem quant s'allunya cada dada de la mitjana. La **desviació** de x_i respecte a la mitjana $\bar{x}$ és:

$$d_i = x_i - \bar{x}.$$

Recordatori

Sempre es compleix que la suma de totes les desviacions és zero: $\sum_i n_i \cdot (x_i - \bar{x}) = 0$. Per això no podem usar la suma de desviacions com a mesura de dispersió.

5.3. La variància

La **variància** (σ^2) és la mitjana dels quadrats de les desviacions:

$$\sigma^2 = \frac{\sum_i n_i \cdot (x_i - \bar{x})^2}{N} = \frac{\sum_i n_i \cdot x_i^2}{N} - \bar{x}^2.$$

La fórmula de la dreta (computacional) és més còmoda per calcular. La variància s'expressa en les **unitats al quadrat** de la variable.

5.4. La desviació típica

La **desviació típica** (σ) és l'arrel quadrada de la variància:

$$\sigma = \sqrt{\sigma^2} = \sqrt{\frac{\sum_i n_i (x_i - \bar{x})^2}{N}}.$$

S'expressa en les **mateixes unitats** que les dades: és la mesura de dispersió més usada.

Interpretació: σ mesura quant s'allunyen, de mitjana, les dades de la mitjana. Una σ petita indica dades molt agrupades; una σ gran, molt escampades.

Exemple

Grups A i B del principi. Calculem σ per al Grup B (notes 3, 5, 7, 9, 11; $\bar{x} = 7$, $N = 5$):

x_i	$(x_i - \bar{x})$	$(x_i - \bar{x})^2$
3	-4	16
5	-2	4
7	0	0
9	2	4
11	4	16
Suma: 0		Suma: 40

$$\sigma^2 = \frac{40}{5} = 8. \quad \sigma = \sqrt{8} \approx 2,83.$$

Per al Grup A: $\sigma^2 = 0$, $\sigma = 0$ (cap dispersió).

Exemple

Amb la fórmula computacional per a les notes (5, 6, 7, 8, 9, 10; $\bar{x} = 6,95$, $N = 20$):

$$\sum n_i x_i^2 = 3 \cdot 25 + 5 \cdot 36 + 6 \cdot 49 + 3 \cdot 64 + 2 \cdot 81 + 1 \cdot 100 = 75 + 180 + 294 + 192 + 162 + 100 = 1003.$$

$$\sigma^2 = \frac{1003}{20} - 6,95^2 = 50,15 - 48,3025 = 1,8475.$$

$$\sigma = \sqrt{1,8475} \approx 1,36 \text{ punts.}$$

Prova-ho tu

Per als 5 valors 2, 4, 4, 4, 6:

- Calcula la mitjana.
- Construeix la taula de desviacions i quadrats de desviacions.
- Calcula la variància i la desviació típica.

Crèdits i llicència

Autoria: Mar Vidal Segura.

Llicència: aquesta obra està subjecta a una llicència Creative Commons **Reconeixement–NoComercial–CompartirIgual 4.0 Internacional** (CC BY-NC-SA 4.0).

CC BY-NC-SA 4.0 <https://creativecommons.org/licenses/by-nc-sa/4.0/deed.ca>

Què pots fer? Compartir i adaptar aquest material **sempre que:** en citis l'autoria (**BY**), no en facis un ús comercial (**NC**) i, si en fas versions, les comparteixis amb la mateixa llicència (**SA**).

Materials de tercers. La llicència anterior cobreix només l'obra original de l'autoria. Els problemes de competició que s'hi citin (Cangur, Copa Cangur i Problemes a l'esprint) són propietat de la Societat Catalana de Matemàtiques i de *Kangourou sans Frontières*, i només s'hi enllaça amb finalitat educativa. El logotip pertany a l'INS Pere Vives. Les imatges o textos d'altri, si n'hi ha, pertanyen als seus titulars.